# SVEUČILIŠTE U RIJECI

# Fakultet informatike i digitalnih tehnologija

Diplomski sveučilišni studij informatike

# KRATKI IZVJEŠTAJ O PRVOM EKPERIMENTALNOM RADU

EKSPERIMENTALNI RAD IZ KOLEGIJA RAČUNALNI VID

Mentori: Prof. dr. sc. Marina Ivašić-Kos

mag. Inf. Kristina Host

Autori: Duje Vidas, Tim Jerić

## Uvod

Cilj ovog zadatka je klasifikacija slika santi leda i brodova. U projektu su se implementirale, trenirale i evaluirale tri jednostavne konvolucijske neuronske mreže (CNN), gdje je krajnji cilj bio odrediti model s najboljim performansama na validacijskom skupu podataka.

## 1. Učitavanje i analiza podataka

Podaci za treniranje i validaciju učitani su iz .npz datoteke (<u>input\_data.npz</u>). Datoteka sadrži sljedeće elemente:

- X\_train i Y\_train: podaci za treniranje
- X\_validation i Y\_validation: podaci za validaciju

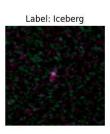
Osnovne informacije o skupu podataka su sljedeće:

- **Dimenzije ulaznih slika:** Svaka slika ima dimenzije 75×75×3, što znači da su slike u boji (RGB format).
- Broj uzoraka za treniranje: 4113 uzoraka
- Broj uzoraka za validaciju: 100 uzoraka
- Klase: [0 Brod, 1 Santa leda]
- Distribucija klasa:
  - o Trening podaci: 2001 brodova i 2112 santi leda (relativno uravnoteženo).
  - Validacijski podaci: 51 brod i 49 santi leda (gotovo potpuno uravnoteženo).
- Nedostajuće vrijednosti (NaN): Nema nedostajućih vrijednosti u podacima.

Prikazano je nekoliko uzoraka slika s pripadajućim oznakama za vizualnu provjeru kvalitete podataka.











## 2. Implementacija CNN modela

Razvijene su tri verzije CNN modela, svaka s različitim razinama složenosti:

#### SimpleCNN\_v1:

- **Slojevi:** Jedan konvolucijski sloj s 8 filtera, kernel veličine 3×3.
- Aktivacija: ReLU
- Pooling: MaxPooling (2×2)
- **Potpuno povezani slojevi:** Jedan sloj s 32 neurona i izlazni sloj s 2 neurona (za binarnu klasifikaciju).

#### SimpleCNN\_v2:

- **Slojevi:** Dva konvolucijska sloja s 32 i 64 filtera, oba kernela veličine 3×3.
- Aktivacija: ReLU
- **Pooling:** MaxPooling (2×2) nakon svakog konvolucijskog sloja.
- Potpuno povezani slojevi: Jedan sloj s 128 neurona i izlazni sloj s 2 neurona.

#### SimpleCNN\_v3:

- **Slojevi:** Tri konvolucijska sloja s 32, 64 i 128 filtera.
- Aktivacija: ReLU
- **Pooling:** MaxPooling (2×2) nakon svakog konvolucijskog sloja.
- Potpuno povezani slojevi: Jedan sloj s 128 neurona i izlazni sloj s 2 neurona.

# 3. Treniranje i validacija modela

Svi modeli trenirani su korištenjem skripte **train.py**, koja podržava:

- Treniranje pojedinačnih modela (v1, v2, v3).
- Treniranje svih modela odjednom.

#### Postavke treniranja:

- Optimizator: Adam
- Funkcija gubitka: CrossEntropyLoss
- Broj epoha: Maksimalno 1000 (s ranim zaustavljanjem)
- Rano zaustavljanje: Aktivira se ako gubitak na validacijskom skupu ne pokazuje poboljšanje kroz 3 uzastopne epohe.
- Metode evaluacije: Točnost (Accuracy), Preciznost (Precision), Odziv (Recall), F1 score

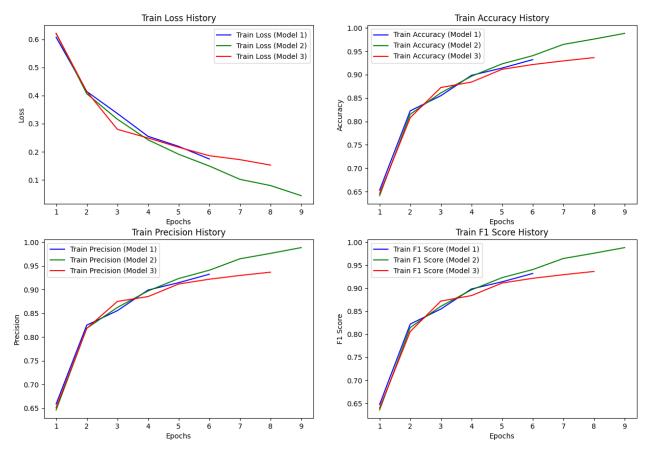
Rezultati treniranja pohranjeni su u JSON datoteke (training\_history\_model\_v1.json, itd.), dok su težine modela spremljene u .pth formate.

## 4. Vizualizacija i analiza metrike

Uz detaljne grafove za metrike treninga i validacije, implementirala se i funkcionalnost za prikaz pojedinačnih slika iz validacijskog skupa s predikcijama modela.

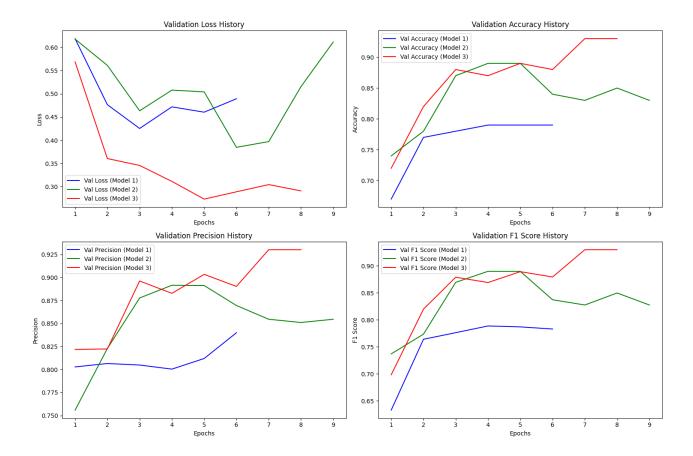
#### Trening metrike:

- 1. **Gubitak:** Svi modeli pokazuju konstantno smanjenje gubitka kroz epohe. Model v2 postiže najniži trening gubitak, što ukazuje na njegovu visoku sposobnost učenja.
- 2. **Točnost:** Sva tri modela pokazuju stalan rast točnosti, pri čemu Model v2 dominira u završnim epohama s najvišom točnošću.
- 3. **Preciznost i F1 score:** Oba pokazatelja značajno rastu tijekom treninga, a Model v2 ima najbolje performanse na trening podacima.



#### Validacijske metrike:

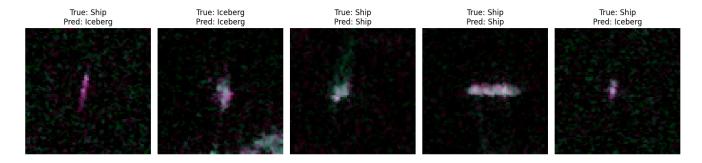
- 1. **Gubitak:** Validacijski gubitak kod Modela v3 pokazuje najmanju varijaciju, dok Model v2 ima oscilacije, što ukazuje na mogući problem s prekomjernim učenjem kod Modela v2.
- 2. **Točnost:** Točnost na validacijskom skupu raste za sve modele tijekom epoha. Model 3 postiže najvišu točnost, dok Model 1 zaostaje. Model 2 pokazuje promjene nakon 5. epohe, što može ukazivati na mogući problem s pretreniranjem ili fluktuacijama u performansama.
- 3. **Preciznost i F1 score:** Model v3 nadmašuje druge modele u ovim pokazateljima, što potvrđuje njegovu preciznost u klasifikaciji brodova i santi leda.



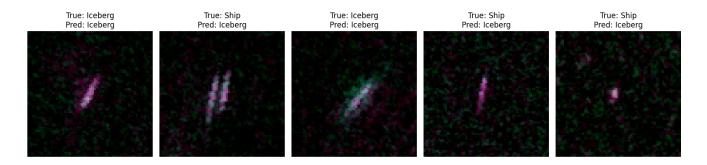
#### Prikaz slika i predikcija:

Kako bi se dodatno evaluirale performanse modela, implementirana je funkcija *display\_predictions*, koja nasumično odabire slike iz validacijskog skupa i prikazuje njihove stvarne i predviđene oznake.

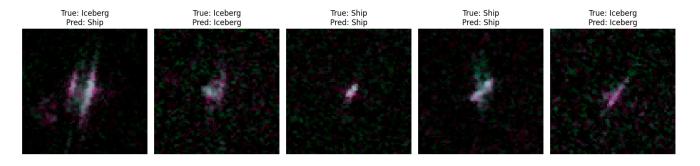
1. **Model v1 - Predikcije:** Slike za Model v1 pokazuju nekoliko netočnih predikcija, uključujući slučajeve gdje je brod klasificiran kao santa leda i obrnuto. Model ima osnovnu sposobnost prepoznavanja, ali često griješi na složenijim slikama.



2. **Model v2 - Predikcije:** Kod Modela v2 vidljivo je poboljšanje u predikcijama, iako su prisutne neke netočnosti. Primjerice, slike s većom "šumnosti" u pozadini otežavaju ispravnu klasifikaciju.



3. **Model v3 - Predikcije:** Model v3 pokazuje najbolje performanse među svim verzijama. Većina predikcija je ispravna, a netočnosti su vrlo rijetke. Ovo potvrđuje stabilnost i robusnost Modela v3 na validacijskom skupu.



# Zaključak

Model 3 pokazuje najbolje performanse i na skupu za treniranje i na skupu za validaciju, s najnižim gubitkom, najvišom točnošću, preciznošću i F1 rezultatom, što ukazuje na dobru generalizaciju.

Model 2 je vrlo dobar na skupu za treniranje, ali pokazuje nestabilnost na validacijskom skupu nakon nekoliko epoha, što može biti znak pretreniranosti. Model 1 ima najslabije performanse u svim metrikama, ali stabilno napreduje kroz epohe. Zbog toga je Model 3 najbolji izbor za generalizaciju na novim podacima, dok bi Model 2 zahtijevao dodatnu provjeru kako bi se izbjegla pretreniranost.