## SVEUČILIŠTE U RIJECI

## Fakultet informatike i digitalnih tehnologija

Diplomski sveučilišni studij informatike

# KRATKI IZVJEŠTAJ O PRVOM EKPERIMENTALNOM RADU

EKSPERIMENTALNI RAD IZ KOLEGIJA RAČUNALNI VID

Mentori: Prof. dr. sc. Marina Ivašić-Kos

mag. Inf. Kristina Host

Autori: Duje Vidas, Tim Jerić

### Uvod

Cilj ovog zadatka bio je osmisliti inovativan način za izbjegavanje sudara brodova sa santama leda, pri čemu se naglasak stavio na razvoj sustava koji može ranije detektirati sante leda i upozoriti posadu. U okviru ovog projekta implementirane su, trenirane i evaluirane tri jednostavne konvolucijske neuronske mreže (CNN) za klasifikaciju slika santi leda i brodova. Krajnji cilj bio je identificirati model s najboljim performansama na validacijskom skupu podataka, čime bi se doprinijelo razvoju učinkovitih alata za prevenciju nesreća.

## 1. Učitavanje i analiza podataka

Podaci za treniranje i validaciju učitani su iz .npz datoteke (<u>input\_data.npz</u>). Datoteka sadrži sljedeće elemente:

- X\_train i Y\_train: podaci za treniranje
- X\_validation i Y\_validation: podaci za validaciju

Kako bi se osigurala odgovarajuća evaluacija, skup podataka za treniranje podijeljen je na novi **train** i **test** skup pomoću funkcionalnosti iz skripte.

#### Karakteristike podataka nakon analize i podjele:

- Dimenzije slika: 75×75×3 (RGB format)
- Broj uzoraka:
  - o Trening skup (X\_train, Y\_train): Ažurirani skup podataka nakon podjele
  - Test skup (X\_test, Y\_test): 1000 uzoraka (500 brodova i 500 santi leda)
  - o Validacijski skup (X\_validation, Y\_validation): 100 uzoraka

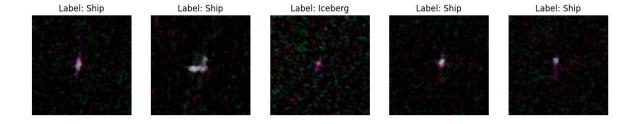
#### Distribucija klasa:

- Trening podaci (X\_train): Ravnomjerno raspoređeni preostali uzorci nakon izdvajanja testnog skupa.
- Test podaci (X\_test): 500 brodova i 500 santi leda (uravnotežen skup).
- Validacijski podaci (X\_validation): 51 brod i 49 santi leda (gotovo uravnoteženo).

#### Dodatna analiza:

• Nedostajuće vrijednosti: Nije pronađeno NaN vrijednosti.

Prikazano je nekoliko uzoraka slika s pripadajućim oznakama za vizualnu provjeru kvalitete podataka.



## 2. Implementacija CNN modela

Razvijene su četiri verzije CNN modela, svaka s različitim razinama složenosti:

#### SimpleCNN\_v1:

- **Slojevi:** Jedan konvolucijski sloj s 8 filtera, kernel veličine 3×3.
- Aktivacija: ReLU
- **Pooling:** MaxPooling (2×2)
- **Potpuno povezani slojevi:** Jedan sloj s 32 neurona i izlazni sloj s 2 neurona (za binarnu klasifikaciju).

#### SimpleCNN\_v2:

- **Slojevi:** Dva konvolucijska sloja s 32 i 64 filtera, oba kernela veličine 3×3.
- Aktivacija: ReLU
- **Pooling:** MaxPooling (2×2) nakon svakog konvolucijskog sloja.
- Potpuno povezani slojevi: Jedan sloj s 128 neurona i izlazni sloj s 2 neurona.

#### SimpleCNN\_v3:

- **Slojevi:** Tri konvolucijska sloja s 32, 64 i 128 filtera.
- Aktivacija: ReLU
- **Pooling:** MaxPooling (2×2) nakon svakog konvolucijskog sloja.
- Potpuno povezani slojevi: Jedan sloj s 128 neurona i izlazni sloj s 2 neurona.

#### SimpleCNN\_v4:

- **Slojevi:** Tri konvolucijska sloja s 32, 64 i 128 filtera.
- Aktivacija: ReLU
- **Pooling:** MaxPooling (2×2) nakon svakog konvolucijskog sloja.
- Regularizacija: Dropout sloj s vjerojatnošću 0.3 za sprječavanje pretreniranosti.
- Potpuno povezani slojevi: Jedan sloj s 128 neurona i izlazni sloj s 2 neurona.

#### Dodatno su se koristili dva pred trenirana modela

#### ResNet:

- **Slojevi:** Korišten je pred trenirani ResNet-18 model, modificiran za binarnu klasifikaciju s 2 izlazna neurona.
- **Potpuno povezani sloj:** Izlazni sloj modificiran za 2 neurona koji omogućuju binarnu klasifikaciju.
- Ulazni oblik: (batch, 3, 75, 75)
- Izlazni oblik: (batch, 2)

#### EfficientNet:

- **Slojevi:** Korišten je pred trenirani EfficientNet-B0 model, modificiran za binarnu klasifikaciju s 2 izlazna neurona.
- Regularizacija: Uključuje dropout sloj s vjerojatnošću 0.2.
- **Potpuno povezani sloj:** Izlazni sloj modificiran za 2 neurona koji omogućuju binarnu klasifikaciju.
- Ulazni oblik: (batch, 3, 224, 224)
- Izlazni oblik: (batch, 2)

## 3. Treniranje i validacija modela

Svi modeli trenirani su korištenjem skripte **train.py**, koja podržava:

- Treniranje pojedinačnih modela (v1, v2, v3, v4, ResNet, EfficientNet).
- Treniranje svih modela odjednom.

#### Postavke treniranja:

- Optimizator: Adam
- Funkcija gubitka: CrossEntropyLoss
- Broj epoha: Maksimalno 1000 (s ranim zaustavljanjem)
- Rano zaustavljanje: Aktivira se ako gubitak na validacijskom skupu ne pokazuje poboljšanje kroz 3 uzastopne epohe.
- Metode evaluacije: Točnost (Accuracy), Preciznost (Precision), Odziv (Recall), F1 score

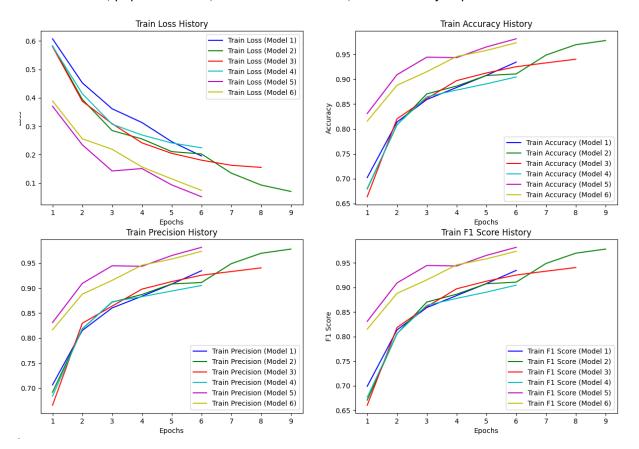
Rezultati treniranja pohranjeni su u JSON datoteke (training\_history\_model\_v1.json, itd.), dok su težine modela spremljene u .pth formate.

## 4. Vizualizacija i analiza metrike

Uz detaljne grafove za metrike treninga i validacije, implementirala se i funkcionalnost za prikaz pojedinačnih slika iz validacijskog skupa s predikcijama modela.

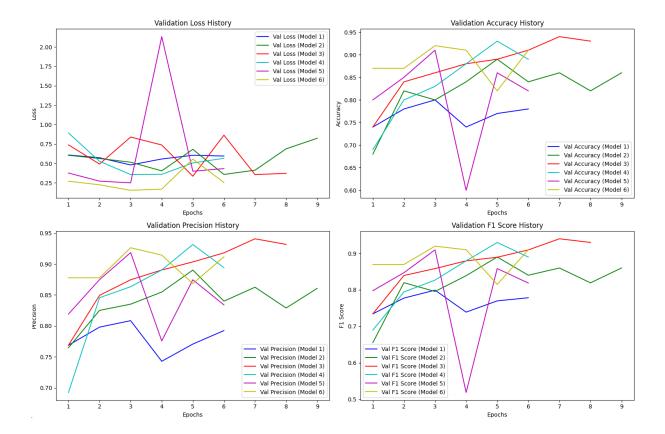
#### Trening metrike:

- 1. **Gubitak:** Svi modeli pokazuju kontinuirani pad gubitka kroz epohe, međutim Model 5 i Model 6 postižu najbolji pad gubitka, što ukazuje na njihovu visoku sposobnost učenja.
- 2. **Točnost:** Svi modeli pokazuju postupan rast točnosti, pri čemu Model 5 dominira u posljednjim epoha s najvišom točnošću.
- 3. **Preciznost i F1 score:** Oba pokazatelja rastu značajno tijekom treninga. Model 5 pokazuje najbolje performanse na trening podacima, posebno u preciznosti i F1 score-u, dok su ostali modeli, poput Modela 3, imali solidne rezultate, ali nešto slabiji napredak.



#### Validacijske metrike:

- 1. **Gubitak:** Validacijski gubitak kod Modela 6 pokazuje najmanju vrijednost, dok Model 3 ima oscilacije, što ukazuje na moguće probleme s pretreniranjem ili nestabilnošću.
- 2. **Točnost:** Točnost na validacijskom skupu raste za sve modele tijekom epoha. Model 3 postiže najvišu točnost, dok Model 6 nižu točnost. Model 1 ima sporiji rast točnosti, dok Model 2 pokazuje solidan napredak do 6. epohe, nakon čega stagnira.
- 3. **Preciznost i F1 score:** Model v3 nadmašuje druge modele u ovim pokazateljima, što potvrđuje njegovu preciznost u klasifikaciji brodova i santi leda, no Model v6 je dosta blizu.



#### **Test metrike**

Rezultati na testnom skupu za sve modele prikazani su u obliku bar grafova:

#### 1. Točnost:

Model 6 ima najbolju točnost s vrijednošću 0.93, dok je Model 1 najslabiji s 0.81. Ostali modeli (Model 2 do Model 5) imaju točnost između 0.87 i 0.91, pri čemu Model 3 postiže 0.91, što ga stavlja u sredinu.

#### 2. Preciznost:

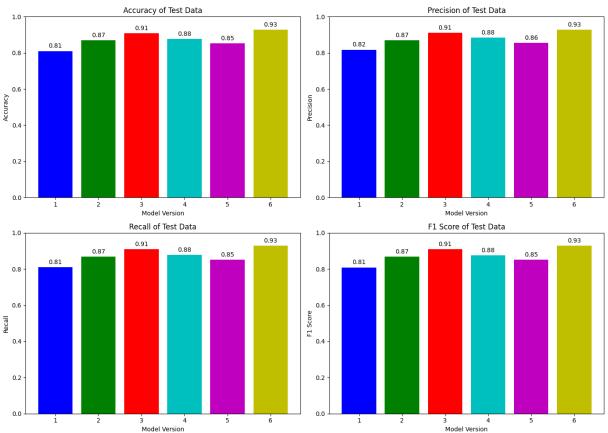
Model 6 ponovno pokazuje najbolje rezultate s 0.93, dok Model 1 ima najnižu preciznost s 0.82. Modeli 3, 4 i 5 su vrlo blizu, s preciznostima od 0.91 do 0.86.

#### 3. Recall

Model 6, kao i kod drugih metrika, ima najbolji recall s 0.93. Modeli 1, 2 i 3 su vrlo slični, s recall vrijednostima oko 0.87 i 0.88, dok su Modeli 4 i 5 nešto niži s 0.85.

#### 4. F1 Score

F1 score je također najbolji kod Modela 6 s 0.93, dok Model 1 ima najniži F1 score s 0.81. Ostali modeli, poput Modela 2, 3 i 4, imaju slične F1 score-ove oko 0.87 do 0.91, s Modelom 3 koji ima 0.91.

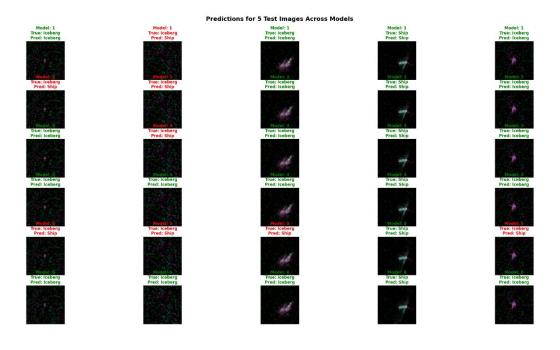


#### Prikaz slika i predikcija:

Kako bi se dodatno evaluirale performanse modela, implementirana je funkcija *display\_predictions*, koja nasumično odabire slike iz validacijskog skupa i prikazuje njihove stvarne i predviđene oznake.

**Točno predviđanje**: Modeli 6 ima dobar učinak, s velikim brojem točnih klasifikacija za testne slike.

**Pogrešna predviđanja**: Modeli 1, 2 i 3 imaju poteškoće u ispravnoj klasifikaciji slika, jer imaju više pogrešnih predviđanja, osobito za slike sa stvarnom oznakom "Iceberg."



## Zaključak

**Model 6** pokazuje najbolje performanse u svim ključnim metrikama: **točnosti**, **preciznosti**, **recallu** i **F1 scoreu**, sa svim vrijednostima u rasponu od **0.93**. Ovaj model se jasno ističe u svim aspektima, što ukazuje na njegovu izuzetnu sposobnost da pravilno klasificira testne podatke, balansirajući točnost i preciznost. Zbog ove visoke sveukupne izvedbe, Model 6 je najpreferiraniji u ovom testiranju.

S druge strane, **Model 1** ima najslabije rezultate u svim metrikama, s **točnošću** od **0.81**, **preciznošću** od **0.82**, **recallom** od **0.81** i **F1 score-om** od **0.81**. Ovi rezultati sugeriraju da Model 1 ima problem s **pravilnim prepoznavanjem i klasificiranjem objekata**, što rezultira nižom preciznošću i recallom, čime gubi u odnosu na ostale modele. Ovaj model se može smatrati manje učinkovitim za ovu specifičnu klasifikaciju.

Modeli 2, 3, 4 i 5 pokazuju slične performanse, pri čemu Model 3 ima najbalansiranije rezultate sa solidnim vrijednostima u svim metrikama. Model 3 postiže točnost i preciznost od 0.91, recall od 0.91 i F1 score od 0.91, što ga čini vrlo konkurentnim, ali ne doseže razinu performansi koju ima Model 6. lako Model 3 pokazuje odlične rezultate, ostali modeli (2, 4 i 5) imaju slične vrijednosti koje su nešto niže, s točnošću i preciznošću u rasponu od 0.87 do 0.88. Ovi modeli još uvijek imaju solidne performanse, ali niže nego Model 6, iako nisu znatno lošiji u odnosu na Model 3.